

Proposal Penelitian Program Doktor Ilmu Komputer
Indeks Kualitas Lingkungan Menggunakan Data Urban Multimodal
Dalam Cakupan Hiper-Lokal



Nama mahasiswa : Manatap Dolok Lauro
NIM : 982023034
Promotor : Prof. Dr. Ir. Eko Sedyono, M.Kom
Co-Promotor 1 : Dr. Ir. Iwan Setyawan, S.T., M.T.
Co-Promotor 2 : Dr. Irwan Sembiring, S.T., M.Kom

Program Studi Doktor Ilmu Komputer
Fakultas Teknologi Informasi
Universitas Kristen Satya Wacana
Salatiga

RINGKASAN

Proposal penelitian ini bertujuan untuk mengatasi keterbatasan Indeks Kualitas Lingkungan Hidup (IKLH) konvensional yang bersifat makro, seperti yang diterapkan di Indonesia khususnya DKI Jakarta. Ditambah lagi, beberapa metode klasifikasi kualitas lingkungan hidup menggunakan metode pemantauan dengan rentang spasial dan temporal yang rendah, seperti stasiun ISPU yang sebarannya jarang dan data satelit (remote sensing) yang beresolusi rendah. Kondisi ini menyebabkan seringkali terdapat kegagalan dalam menangkap variabilitas kualitas lingkungan pada skala hiper-lokal. Padahal, paparan polusi individu sangat bergantung pada kondisi hiper-lokal di lokasi aktivitas tetap seperti rumah atau kantor. Sebagai solusi, penelitian ini mengajukan pengembangan Multimodal Hyper-Local Smart Environment Quality Index (MHL-SmartEQI). Kebaruan utama terletak pada fusi data multimodal pada resolusi hiper-lokal menggunakan pendekatan deep learning. Model ini akan mengintegrasikan beragam sumber data urban, termasuk data remote sensing (citra satelit untuk segmentasi tutupan lahan), data realtime dari ground sensor (polusi udara), data visual dari kamera (mobilitas penduduk), dan data audio (polusi suara kebisingan). Tujuan khusus penelitian adalah membangun model prediksi indeks kualitas lingkungan hidup untuk mencapai pemantauan real-time. Luaran yang diharapkan mencakup model MHL-SmartEQI, publikasi ilmiah, dan dataset urban multimodal hiper-lokal.

DAFTAR ISI

RINGKASAN	1
DAFTAR ISI	2
BAB 1. PENDAHULUAN	4
1.1. Latar Belakang	4
1.2. Rumusan Masalah	7
1.3. Ruang Lingkup Penelitian.....	8
1.4. Manfaat Penelitian.....	8
1.5. Tujuan Khusus Penelitian.....	9
1.6. Urgensi Penelitian	9
1.7. Kontribusi dalam Area Penelitian (Novelty).....	9
1.8. Luaran Penelitian yang Diharapkan	10
BAB 2. TINJAUAN PUSTAKA.....	11
2.1. Indeks Kualitas Lingkungan Hidup.....	11
2.2. Indeks Kualitas Air.....	11
2.3. Indeks Kualitas Air Laut	12
2.4. Indek Kualitas Udara.....	13
2.5. Indeks Kualitas Lahan.....	15
2.6. Semantic Segmentation	16
2.7. U-Net.....	17
2.8. You-Only-Look-Once.....	22

2.9.	Slicing Aided Hyper Inference	24
2.10.	Data Suara Kebisingan Jalan Raya.....	24
2.11.	Ekstraksi Fitur Pada Data Suara Kebisingan Jalan Raya	27
2.12.	Roadmap Penelitian.....	29
BAB 3. Metodologi Penelitian		30
3.1.	Tahapan Penelitian	30
3.2.	Desain Penelitian.....	30
3.3.	Luaran Penelitian.....	31
3.4.	Lokasi Penelitian.....	31
3.5.	Indikator Pencapaian	32
3.6.	Alat dan Bahan Penelitian	32
BAB 4. JADWAL PENELITIAN		34
4.1.	Jadwal Penelitian.....	34
DAFTAR PUSTAKA		36

BAB 1. PENDAHULUAN

1.1. Latar Belakang

Kehidupan di perkotaan merupakan suatu sistem lingkungan yang kompleks. Interaksi antara komponen biotik, abiotik, dan aktivitas manusia menciptakan tantangan tersendiri dalam mengelola lingkungan. Dalam hal kualitas lingkungan hidup, setiap penyelenggara pemerintahan membutuhkan suatu indeks yang menggambarkan keadaan lingkungan hidup dalam wilayah administrasinya. Indeks ini dapat berguna untuk beberapa hal, yaitu memberikan informasi kepada para pengambil keputusan tingkat nasional dan daerah, dan digunakan juga untuk melakukan evaluasi kebijakan pembangunan yang berkelanjutan dan berwawasan lingkungan.

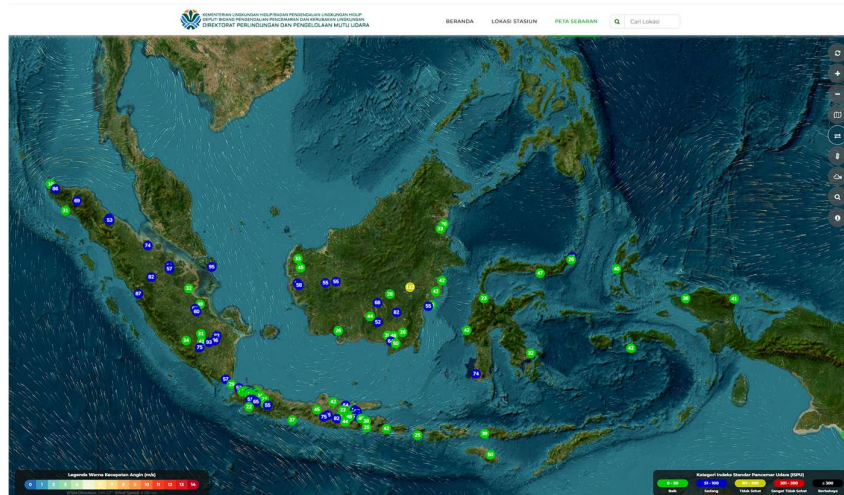
Beberapa contoh model Indeks Lingkungan Hidup yang sudah diterapkan oleh negara-negara maju antara lain: Amerika Serikat menggunakan Environmental Quality index EQI 2006-2010 [1], Perancis menggunakan Environment Performance Index (EPI) [2], sedangkan Jepang menggunakan berbagai indeks untuk masing-masing variable dalam menentukan kualitas lingkungan hidup [3].

Berdasarkan data dari Badan Pusat Statistik, negara Indonesia menyajikan data lingkungan hidup dalam bentuk dokumen statistik [4]. Namun, dokumen ini menyajikan data berupa besaran variable berdasarkan provinsi, serta pengambilan data yang dilakukan periodik pertahun. Sedangkan di Provinsi DKI Jakarta, Dinas Lingkungan Hidup (DLH) menyajikan data dengan cara yang lebih dapat dipahami oleh masyarakat, yaitu dengan menampilkan Indeks Kualitas Lingkungan Hidup (IKLH) [5]. Dalam menghasilkan IKLH tahunan, DLH Provinsi DKI menggunakan beberapa sumber data yang menghasilkan indeks sebagai berikut: Indeks Kualitas Air (IKA), Indeks Kualitas Udara (IKU), Indeks Kualitas Lahan (IKL), dan Indeks Kualitas Air Laut (IKAL).

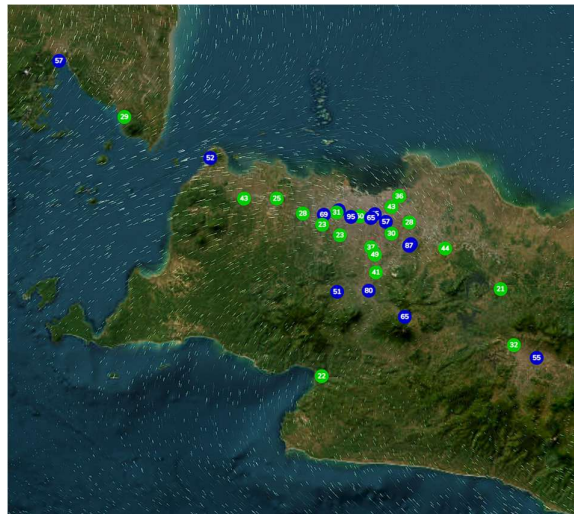
Pemerintahan yang menerapkan pengukuran IKLH dalam pengambilan keputusan dan kebijakan sejalan dengan point 11 Sustainable Cities and Communities dalam Sustainable Development Goals 2030. Penggunaan indeks ini mendukung perencanaan, dan menjamin kelangsungan pembangunan pada tingkat urban perkotaan [6]. Selain itu, penggunaan indeks ini juga mendukung dimensi Smart Environment pada Smart City. Dimensi ini pada Smart City menargetkan penggunaan teknologi dalam mengatur sumber daya alam dan mendukung target pembangunan yang berkelanjutan [7].

Namun, kebutuhan atas IKLH dalam cakupan yang jauh lebih sempit semakin menjadi tuntutan masyarakat saat ini. Sebagai pusat pemerintahan, ekonomi, dan industri, DKI Jakarta mengalami pertumbuhan pesat di sektor permukiman, perdagangan, dan infrastruktur. Pada tahun 2024, populasi kota ini mencapai 10,68 juta jiwa dengan kepadatan 16.165 per km². Perkembangan ini membawa tantangan lingkungan serius, terutama penurunan kualitas lingkungan akibat kegiatan manusia yang berdampak signifikan pada lingkungan.

Kualitas udara merupakan isu yang semakin menjadi perhatian, namun data yang relevan seringkali tidak tersedia pada tingkat yang dibutuhkan. Pemantauan kualitas udara tradisional seperti Stasiun Pemantauan Indeks Standar Pencemar Udara dan data remote sensing (citra satelit) seringkali memiliki keterbatasan. Informasi yang berasal dari stasiun ISPU seharusnya memberikan gambaran kualitas udara di lokasi stasiun tersebut berada, namun sebaran stasiun ini sangat jarang, yang mengakibatkan bacaan dari stasiun tidak dapat mewakili daerah lain yang mungkin memiliki variabilitas yang tinggi. Sebagai contoh, di provinsi DKI Jakarta hanya memiliki 3 stasiun pemantauan ISPU yang berlokasi di: Marunda (Cilincing-Jakarta Utara), Gelora Bung Karno (Jakarta Pusat), dan Kebon Nanas (Jatinegara-Jakarta Timur) [8].



Gambar 1.1. Peta Sebaran Stasiun Pemantauan Indeks Standar Pencemar Udara Seluruh Indonesia [9]



Gambar 1.2. Peta Sebaran Stasiun Pemantauan ISPU, Fokus Pada Kota Jakarta dan Sekitarnya [9]

Di sisi lain, data remote sensing memiliki cakupan yang terlalu luas yang mengakibatkan resolusi spasial rendah, serta memiliki periode pengambilan data yang terlalu panjang (resolusi temporal rendah) untuk menangkap variabilitas polusi di tingkat jalanan. Sebagai contoh satelit Copernicus Sentinel-5P, yang memiliki fungsi untuk memonitor kondisi atmosfer bumi dalam hal kualitas udara, lapisan ozon, dan perubahan iklim, memiliki waktu orbit setiap 16 hari [10].

Dalam konteks cakupan hiper-lokal, kualitas udara dapat bervariasi secara drastis walaupun hanya dalam jarak beberapa ratus meter. Keadaan ini menjadi kritis karena kegiatan manusia sehari-hari seringkali berada pada lokasi tetap untuk jangka waktu lama, seperti rumah, sekolah,

atau kantor. Paparan polusi individu sangat bergantung pada kondisi hiper-lokal di lokasi-lokasi tersebut, yang tidak dapat ditangkap oleh data makro.

Untuk dapat menentukan kualitas lingkungan yang akurat, dibutuhkan berbagai sumber data, antara lain kandungan polutan dalam udara, tutupan lahan, mobilitas penduduk, suara lingkungan, dan lain-lain [11]. Kualitas lingkungan ini berdampak langsung pada kesehatan dan kesejahteraan penduduk, yang seringkali beraktivitas pada lokasi tetap dalam jangka waktu yang lama, seperti di rumah, sekolah, atau kantor.

Tantangan utamanya tidak hanya terletak pada pengumpulan data, tetapi juga pada bagaimana mengintegrasikan data yang beragam ini menjadi satu metrik yang bermakna. Dibutuhkan sebuah indeks komposit yang dapat menyederhanakan data kompleks ini, serta sistem prediksi berdasarkan data historis untuk mengantisipasi perubahan di masa mendatang. Lebih lanjut, agar berguna secara praktis, informasi tersebut harus disajikan dalam format yang mudah diakses dan dipahami, seperti dashboard interaktif, yang memungkinkan pemantauan muda, cepat, dan real-time.

Penelitian ini mengajukan Multimodal Hyper-Local Smart Environment Quality Index (MHL-SmartEQI), yaitu peningkatan dari model IKLH yang sudah ada sebelumnya dengan menambahkan data semi-reltime seperti: Segmentasi tutupan lahan yang diambil dari citra satelit; dan data realtime seperti: Mobilitas penduduk yang diambil dari kamera cctv di jalan raya secara real-time, polusi udara dari ground sensor, serta polusi suara dari kemacetan. Selain itu, informasi yang disajikan bersifat hiper-lokal, sehingga dapat digunakan masyarakat untuk memantau kualitas lingkungan hidup di sekitarnya.

1.2. Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, rumusan masalah penelitian dapat dijelaskan sebagai berikut:

1. Bagaimana data urban multimodal dapat diintegrasikan secara efektif untuk memodelkan dan menghasilkan MHL-SmartEQI secara hiper-lokal di lingkungan perkotaan?
2. Seberapa akurat model yang dikembangkan dapat menghitung IKLH pada skala hiper-lokal?
3. Bagaimana hasil prediksi MHL-SmartEQI ini dapat disajikan secara efektif untuk memberikan informasi risiko kesehatan yang dapat ditindaklanjuti bagi masyarakat?

1.3. Ruang Lingkup Penelitian

Ruang lingkup penelitian yang dilihat dari sudut pandang data, lokasi, model, dan luaran dijelaskan sebagai berikut:

1. Data: Penelitian menggunakan data multimodal yang berasal dari ground sensor dan remote sensing.
2. Lokasi: Studi kasus difokuskan pada area terbatas di dalam wilayah Provinsi DKI Jakarta yang memiliki ketersediaan data sensor yang memadai.
3. Model: Fokus pemodelan adalah model prediksi menggunakan data multimodal.
4. Luaran: Hasil akhir penelitian adalah pemodelan indeks kualitas lingkungan hidup MHL-SmartEQI. Penelitian ini tidak mencakup pengembangan perangkat keras sensor baru.

1.4. Manfaat Penelitian

Secara umum, penelitian ini bertujuan untuk mengembangkan dan memvalidasi model prediksi MHL-SmartEQI yang akurat menggunakan pendekatan fusi data multimodal hiperlokal di DKI Jakarta.

Penelitian ini diharapkan dapat memberikan manfaat sebagai berikut:

1. Bagi Masyarakat: Menyediakan informasi indeks kualitas lingkungan hidup dalam cakupan hiper-lokal yang akurat dan real-time.

2. Bagi Pembuat Kebijakan: Menyediakan alat bantu monitoring indeks kualitas lingkungan hidup yang lebih presisi untuk mengevaluasi efektivitas kebijakan pembangunan.
3. Bagi Akademisi: Memberikan kontribusi berupa dataset dan pemodelan prediksi indeks kualitas lingkungan hidup pada skala hiper-lokal.

1.5. Tujuan Khusus Penelitian

Adapun tujuan khusus dari penelitian ini adalah:

1. Membangun model prediksi indeks kualitas lingkungan hidup hiper-lokal dengan mengintegrasikan data multimodal ground sensor dan remote sensing.
2. Mengembangkan prototipe dashboard interaktif sebagai media visualisasi dan monitoring perubahan indeks kualitas lingkungan hidup secara hiper-lokal dan real-time.

1.6. Urgensi Penelitian

Kesehatan lingkungan yang buruk di Jakarta merupakan krisis kesehatan publik yang membutuhkan intervensi segera. Ketergantungan pada data berskala makro tidak dapat memberikan peringatan yang relevan bagi individu di tingkat komunitas. Mengingat sebagian besar paparan terjadi di lokasi-lokasi tetap (rumah, sekolah, kantor), ketersediaan data hiper-lokal menjadi sangat mendesak. Penelitian ini penting untuk mengisi kesenjangan data tersebut yang dapat segera dimanfaatkan untuk mitigasi risiko kesehatan di tingkat individu.

1.7. Kontribusi dalam Area Penelitian (Novelty)

Kebaruan utama (novelty) dari penelitian ini terletak pada aspek berikut ini:

1. Fusi Data Multimodal, yaitu metode integrasi beragam sumber data urban antara lain: data visual dari kamera, data audio dari mikrofon, data polutan udara, dan data tutupan lahan dari satelit untuk menciptakan model prediktif yang lebih holistik dan akurat.

2. Resolusi hiper-lokal, untuk mencapai tujuan resolusi spasial dan temporal yang sangat tinggi, yaitu dalam tingkat lingkungan atau jalan, yang melampaui kemampuan model IKLH yang saat ini masih digunakan.

1.8. Luaran Penelitian yang Diharapkan

Berikut adalah rencana luaran penelitian yang diharapkan:

Tabel 1.1. Luaran Penelitian

No	Bentuk	Deskripsi	Penjelasan
1	Makalah Ilmiah	International Conference Paper dengan topik “Optimizing Small Object Detection”	Pokok studi yang ditulis pada makalah ilmiah ini seputar penggunaan model dengan optimalisasi deteksi obyek kecil dari citra yang berasal dari satelit. Tujuannya adalah untuk mendeteksi obyek-obyek penghasil polutan udara.
2	Makalah Ilmiah	International Reputable Journal dengan topik “Deep Learning for City Traffic Level Classification”	Makalah ilmiah ini membahas kemajuan teknik dan use case terbaru seputar deteksi kemacetan jalan perkotaan, beserta tantangannya dalam kondisi sesungguhnya.
3	Makalah Ilmiah	Internasional Reputable Journal dengan topik “MHL-SmartEQI: Model Deep Learning untuk Indeks Kualitas Lingkungan Hidup Perkotaan dengan data multimodal”	Makalah ilmiah ini memiliki tujuan untuk menghasilkan model indeks kesehatan lingkungan hidup dalam skala hiperlokal.
4	Dataset	Urban Multimodal Hyper-Local Dataset	Dataset hasil fusi data multimodal yang dapat digunakan untuk penelitian selanjutnya.
5	Model	MHL-SmartEQI	Multimodal Hyper-Local Smart Environment Quality Index

BAB 2. TINJAUAN PUSTAKA

2.1. Indeks Kualitas Lingkungan Hidup

Indeks Kualitas Lingkungan Hidup (IKLH) didefinisikan sebagai suatu metrik komposit yang menyajikan evaluasi kuantitatif terhadap kondisi lingkungan dalam cakupan spasial dan temporal yang spesifik. Secara historis, penilaian kualitas lingkungan cenderung dilaksanakan secara terpisah, yaitu berfokus pada media individual seperti air, udara, dan lahan. Pendekatan parsial tersebut menimbulkan kendala bagi publik untuk memahami secara komprehensif mengenai status lingkungan suatu wilayah. Penggabungan beragam data ke dalam format indeks merupakan salah satu metodologi untuk menghasilkan informasi yang lebih sederhana, sehingga memfasilitasi pengetahuan yang lebih aksesibel bagi masyarakat luas .

Untuk wilayah DKI Jakarta, Dinas Lingkungan Hidup menghasilkan Indeks Kualitas Lingkungan Hidup dengan melakukan pengukuran terhadap beberapa variable, antara lain: Indeks Kualitas Udara (IKU), Indeks Kualitas Air (IKA), Indeks Kualitas Air Laut (IKAL), dan Indeks Kualitas Lahan (IKL). Keseluruhan indeks ini kemudian dikombinasikan untuk menghasilkan suatu besaran berupa Indeks Kualitas Lingkungan Hidup tingkat Provinsi yang mewakili seluruh variable yang menjadi perhatian studi lingkungan (1).

$$IKLH\ Prov = (34\% \times IKA) + (42.8\% \times IKU) + (13.3\% \times IKL) + (9.9\% \times IKAL) \quad (1)$$

2.2. Indeks Kualitas Air

Indeks Kualitas Air (IKA) merupakan suatu metrik evaluatif yang digunakan untuk mengasesmen kondisi perairan secara periodik, yang dihitung berdasarkan komparasi antara parameter terukur dengan standar kualitas (baku mutu) rujukan. Asesmen ini bertujuan mengidentifikasi tingkat pencemaran serta menentukan kelayakan fungsional air untuk beragam peruntukan. Landasan yuridis yang digunakan sebagai referensi baku mutu adalah Peraturan Pemerintah No. 22 Tahun 2021 (Lampiran VI), yang menetapkan standar kualitas air

secara terdiferensiasi berdasarkan klasifikasi fungsional badan air, guna mendukung manajemen sumber daya air yang berkesinambungan. Parameter spesifik yang dianalisis mengacu pada Peraturan Menteri LHK No. 27 Tahun 2021, mencakup delapan parameter untuk air sungai (pH, DO, COD, TSS, BOD, Fecal coli, Total Fosfat, dan Nitrat) serta sepuluh parameter untuk danau atau waduk (ditambah Kecerahan, Klorofil- α , dan Total Nitrogen).

Proses kalkulasi IKA diawali dengan penetapan status mutu air di setiap lokasi pemantauan menggunakan metode Indeks Pencemaran (IP). Metode IP ini mengalkulasi rasio konsentrasi parameter kualitas air aktual terhadap baku mutu yang relevan untuk setiap peruntukan. Nilai IP yang diperoleh kemudian diklasifikasikan ke dalam kategori status mutu (baik, cemar ringan, sedang, atau berat) sesuai ambang batas yang telah ditentukan. Kategori status mutu inilah yang selanjutnya dikonversi menjadi nilai IKA final, yang berfungsi sebagai indikator komprehensif untuk menunjang pengelolaan kualitas air dan evaluasi kebijakan lingkungan.

2.3. Indeks Kualitas Air Laut

Indeks Kualitas Air Laut (IKAL) didefinisikan sebagai indikator kuantitatif yang merefleksikan kondisi perairan laut pada lokus dan waktu spesifik. Aktivitas pemantauan lingkungan perairan, sebagaimana diimplementasikan di Teluk Jakarta dan kawasan Kepulauan Seribu, bertujuan untuk melakukan evaluasi terhadap status mutu air laut di wilayah tersebut. Hasil asesmen ini kemudian berfungsi sebagai rujukan fundamental dalam perumusan kebijakan pengendalian pencemaran serta mitigasi kerusakan lingkungan.

Secara metodologis, penentuan IKAL mengadaptasi kerangka kerja umum Water Quality Index (WQI). Salah satu WQI yang sering dirujuk adalah National Sanitation Foundation Water Quality Index (NSF-WQI), yang digunakan untuk menilai dan mengklasifikasikan tingkatan kualitas suatu badan air. Kalkulasi indeks komposit ini didasarkan pada sembilan parameter terukur, yakni total padatan, kekeruhan, temperatur, fosfat (PO_4), nitrat (NO_3), BOD, pH, fecal

coli, dan oksigen terlarut (DO), di mana setiap parameter diberikan bobot nilai yang spesifik (Lihat tabel 2.1.) dalam perhitungan (2).

Tabel 2.1. Nilai Bobot Parameter Penilaian Mutu Air Laut

No	Parameter (Q)	Bobot (W)
1	Total Padatan	0.08
2	Kekeruhan	0.08
3	Temperatur	0.1
4	PO4	0.1
5	NO3	0.1
6	BOD	0.1
7	pH	0.12
8	Fecal coli	0.15
9	DO	0.17

$$WQI = \sum_{i=1}^n QiWi \quad (2)$$

Hasil perhitungan tersebut kemudian dikategorikan berdasarkan kriteria National Sanitation Foundation-Water Quality Index (NSF-WQI), sebagaimana disajikan pada Tabel 2.2.

Tabel 2.2. Kategori Indeks Kualitas Air Laut

No	Kategori	Angka Rentang
1	Sangat Baik	$90 \leq x \leq 100$
2	Baik	$70 \leq x < 90$
3	Sedang	$50 \leq x < 70$
4	Kurang	$25 \leq x < 50$
5	Sangat Kurang	$0 \leq x < 25$

2.4. Indeks Kualitas Udara

Kualitas udara merujuk pada kondisi udara ambien dalam kaitannya dengan dampaknya terhadap kesehatan manusia dan ekosistem. Udara dinilai berkualitas baik ketika udara tidak mengandung polutan dalam konsentrasi yang dapat menimbulkan efek negatif. Polusi udara terjadi ketika atmosfer terkontaminasi oleh zat-zat berbahaya, baik yang berasal dari sumber alami maupun aktivitas manusia (antropogenik). Berdasarkan penelitian pada bidang kesehatan yang telah dilakukan [12], polusi udara dikategorikan sebagai "silent public health emergency

", dan memerlukan kesadaran masyarakat yang dikombinasikan dengan solusi dari para pakar untuk menangani masalah polusi udara yang semakin buruk .

Bukti ilmiah menunjukkan korelasi kuat antara paparan polutan di udara, terutama Particulate Matter (PM), O₃ (ozon), NO₂, SO₂, dan logam berat seperti Timbal (Pb), Polycyclic Aromatic Hydrocarbons (PAHs), dan Volatile Organic Compounds (VOCs), dengan berbagai dampak kesehatan yang merugikan seperti kerusakan saluran napas, penyakit jantung, dan paru-paru [13]. Penelitian tersebut juga menyimpulkan bahwa kualitas udara yang buruk secara langsung mempengaruhi kesehatan manusia dengan menyebabkan disfungsi multisistemik, termasuk gangguan pernapasan, kardiovaskular, dan neurologis, yang pada akhirnya berkontribusi signifikan terhadap peningkatan angka morbiditas dan mortalitas global.

Proses kalkulasi didasarkan pada perbandingan antara data rata-rata tahunan dan standar rujukan European Union (EU) Directives. Signifikansi standar EU Directives ini diperkuat oleh fakta bahwa standar tersebut masih diperhitungkan oleh World Health Organisation (WHO) sebagai dasar dalam menentukan baku mutu kualitas udara.

Tabel 2.3. Standar Kualitas Udara Berdasarkan EU Directives

Kualitas Udara	Nilai Indeks (I_{EU})
Melebihi baku mutu EU oleh satu atau lebih parameter polutan	>1
Memenuhi rata-rata Standar EU	1
Kondisi lebih baik dari rata-rata persyaratan normal	≤ 1

Tabel 2.4. Baku Mutu Penentuan Kualitas Udara Menurut EU Directives

Polutan	Baku Mutu EU Directives
NO ₂	Nilai tahunan 40 $\mu\text{g}/\text{m}^3$
SO ₂	Nilai tahunan 20 $\mu\text{g}/\text{m}^3$

Selanjutnya, indeks udara model I_{EU} dikonversikan menjadi Indeks Kualitas Udara (IKU) melalui persamaan (3) sebagai berikut.

$$IKU = 100 - \left(\frac{50}{0,9}(I_{EU} - 0,1)\right) \quad (3)$$

Nilai IKU yang telah dihitung selanjutnya diklasifikasi merujuk pada Tabel 2.5.

Tabel 2.5. Kategori Indeks Kualitas Udara

No	Kategori	Angka Rentang
1	Sangat Baik	$90 \leq x \leq 100$
2	Baik	$70 \leq x < 90$
3	Sedang	$50 \leq x < 70$
4	Kurang	$25 \leq x < 50$
5	Sangat Kurang	$0 \leq x < 25$

2.5. Indeks Kualitas Lahan

Indeks Kualitas Lahan (IKL) didefinisikan sebagai suatu nilai yang merepresentasikan kualitas tutupan lahan. Penutup lahan (Land Cover) didefinisikan sebagai tutupan biofisik pada permukaan bumi yang dapat diamati, yang sekaligus merepresentasikan hasil dari pengaturan, aktivitas, dan perlakuan manusia (intervensi antropogenik) pada area tersebut untuk tujuan produksi, perubahan, atau pemeliharaan. Klasifikasi penutup lahan dilakukan berdasarkan kesamaan kenampakan biofisiknya, yang dikelompokkan ke dalam beberapa kelas, meliputi: hutan, permukiman, badan air, pertanian tanah kering, pertanian tanah basah, semak belukar, dan tanah terbuka.

Penentuan nilai ini didasarkan pada kalkulasi parameter Indeks Tutupan Lahan (ITL). Landasan metodologis untuk perhitungan ITL dan IKL telah ditetapkan secara formal dalam Peraturan Menteri Lingkungan Hidup dan Kehutanan Republik Indonesia No. 27 Tahun 2021 tentang Indeks Kualitas Lingkungan Hidup. Perolehan nilai IKL secara kuantitatif didasarkan pada aplikasi rumus (4) berikut.

$$IKL = 100 - \left[(84,3 - (ITL \times 100)) \frac{50}{54,3} \right] \quad (4)$$

Sedangkan ITL didapatkan dari Luas Tutupan Lahan Hijau (LTLH), Luas Tutupan Lahan Non Hijau (LTLNH), dan Luas Wilayah (LW) dengan rumus (5) sebagai berikut.

$$ITL = \frac{(\sum LTLH \times 1) + (\sum LTLNH \times 0,6)}{LW} \quad (5)$$

Tabel 2.6. Kategori Indeks Kualitas Lahan

No	Kategori	Angka Rentang
1	Sangat Baik	$90 \leq x \leq 100$
2	Baik	$70 \leq x < 90$
3	Sedang	$50 \leq x < 70$
4	Kurang	$25 \leq x < 50$
5	Sangat Kurang	$0 \leq x < 25$

2.6. Semantic Segmentation

Semantic segmentation memiliki peran penting dalam perkembangan teknologi di bidang computer vision dan machine learning [14]. Penggunaan semantic segmentation berperan penting dalam remote sensing yang memiliki berbagai pengaplikasian informasi geografis, yaitu perencanaan kota, pengelolaan lahan, perlindungan lingkungan, dan pertanian yang presisi [15]. Meskipun semantic segmentation berkaitan erat dengan panoptic segmentation, instance segmentation, object segmentation, dan image segmentation, dimana seluruh metode ini digunakan untuk mengidentifikasi objek, terdapat perbedaan pada pendekatan yang dilakukan dan tingkat detail pada hasil yang diberikan [16].

Kemampuan yang dimiliki semantic segmentation untuk melakukan pixel-level classification adalah sebuah tugas yang penting namun sulit untuk dilakukan. Piksel yang memiliki nilai yang serupa dianotasi kepada label yang sama, sehingga membuat algoritma semantic segmentation dapat melakukan pendeteksian, pengenalan, dan segmentasi pada citra [15]. Semantic segmentation akan mengelompokkan objek-objek yang serupa ke dalam kelas yang sama.



Gambar 2.1. Visualisasi Segmentasi pada Metode Panoptic [16]



Gambar 2.2. Visualisasi Segmentasi pada Metode Semantic [16]

Pada tahap awal perkembangan penelitian mengenai semantic segmentation, model umumnya dibangun menggunakan pendekatan non-deep learning, seperti metode thresholding, clustering-based, edge detection, dan conditional random field [15]. Namun, metode machine learning tersebut cenderung menghasilkan akurasi yang rendah serta kurang efisien dalam proses komputasi. Sehingga, mulai dilakukan pengaplikasian deep learning untuk melakukan semantic segmentation. Sehingga, Convolutional Neural Network (CNN) digunakan untuk melakukan semantic segmentation, namun CNN tidak menghasilkan performa yang baik pada semantic segmentation dibandingkan dengan image classification [16]. Oleh karena itu, para peneliti mulai mengembangkan model deep learning yang dibangun berdasarkan CNN, seperti Fully Connected Network, U-Net, SegNet, dan DeepLab [15].

2.7. U-Net

U-Net adalah sebuah convolutional network yang diciptakan oleh Ronneberger pada tahun 2015 yang ditujukan untuk melakukan image segmentation di bidang medis [17]. Saat ini, penggunaan U-Net banyak ditemukan di bidang remote sensing. Arsitektur U-Net berbentuk menyerupai huruf “U” yang memiliki dua bagian utama, yaitu bagian di sebelah kiri yang disebut dengan extraction part atau lower sampling part atau contraction path atau encoder, dan sebelah kanan yang disebut upper sampling part atau expansive path atau decoder [17], [18].

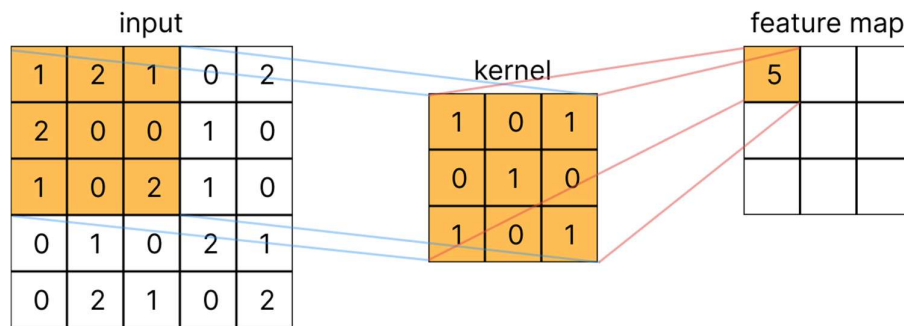
Convolutional adalah proses mengekstraksi informasi pola visual (tepi, sudut, dan lainnya) pada gambar menggunakan filter untuk mengekstraksi fitur dari input layer dan menjadi sebuah feature map. Peningkatan jumlah filter akan mempengaruhi kemampuannya dalam melakukan ekstraksi, namun juga akan meningkatkan kompleksitas perhitungan [19]. Filter akan bergerak secara horizontal dan vertikal ke seluruh bagian input yang kemudian hasil perhitungan dari setiap tahap akan menjadi nilai singular yang akhirnya akan menjadi sebuah feature map. Pergerakan filter mengelilingi seluruh bagian input diatur dengan stride, yaitu jumlah piksel yang akan digeser oleh filter setiap kali perhitungan dilakukan. Perhitungan feature map dilakukan dengan melakukan operasi hitung perkalian dan penjumlahan nilai piksel pada setiap posisi input yang sedang dilakukan proses perhitungan. Setiap nilai piksel pada input akan dikalikan dengan nilai kernel dan dilakukan hingga seluruh piksel, kemudian hasil dari masing-masing nilai piksel yang dikalikan akan dijumlahkan dan menjadi satu nilai piksel di feature map. Kernel adalah matriks kecil yang menyusun sebuah filter (misalnya berukuran 3 x 3 atau 5 x 5). Rumus dan gambar di bawah memberikan cara perhitungan dan visualisasi convolution layer.

$$S_{(i,j)} = (X \times W)_{(i,j)} = \sum_m \sum_n X_{(i+m,j+n)} W_{(m,n)} \quad (6)$$

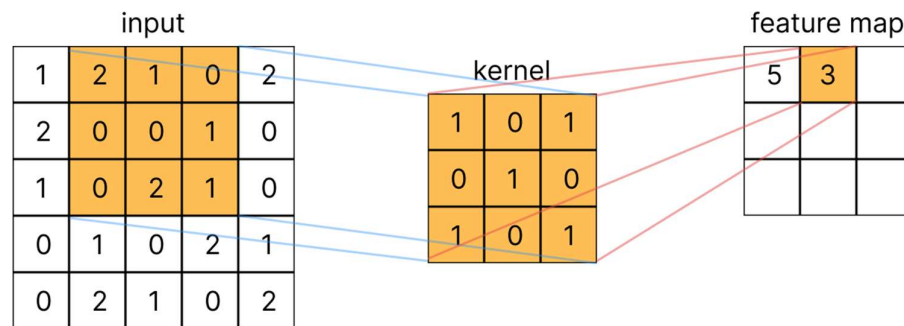
S = Feature Map

X = Matriks input

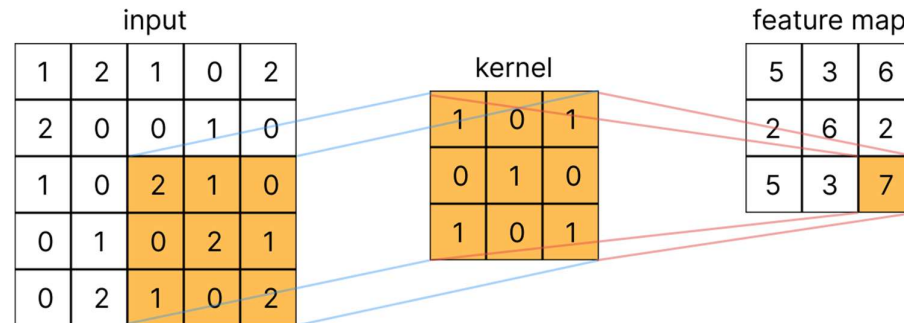
W = Matriks kernel



Gambar 2.3. Langkah-langkah Convolution Layer Tahap 1



Gambar 2.4. Langkah-langkah Convolution Layer Tahap 2



Gambar 2.5. Langkah-langkah Convolution Layer Tahap 3


Kemudian, hasil dari feature map akan dihitung kembali menggunakan fungsi aktivasi Rectified Linear Unit (ReLU). ReLU adalah fungsi aktivasi yang paling populer dalam pengaplikasian Convolutional Neural Network karena ReLU mampu memangkas waktu dan sumber daya komputasi. ReLU berfungsi untuk mengembalikan nilai nol pada setiap nilai negatif dan mengembalikan nilai awal pada setiap nilai positif. ReLU juga mengatasi masalah vanishing gradient yang terjadi ketika nilai dari gradien hampir mencapai nol dan tidak ada nilai yang benar-benar signifikan untuk digunakan sebagai pembelajaran, sehingga pembelajaran

yang terjadi tidak efektif. Hasil nilai gradien dari ReLU selalu 0 untuk nilai negatif dan 1 untuk nilai positif, sehingga hal ini menjadi kelebihan ReLU dalam melakukan pembelajaran karena nilai yang tidak efektif akan diabaikan dan fokus kepada nilai yang memberikan pembelajaran penting. Rumus fungsi aktivasi ReLU dapat dilihat pada rumus di bawah.

$$f(x) = \max(0, x) \quad (7)$$

x = nilai input

Pooling adalah proses mengecilkan dimensi spasial (downsampling) sehingga membuat model dapat melihat visual pada konteks yang lebih luas dan mengurangi sumber daya komputasi. Salah satu teknik pooling yang paling populer adalah max pooling. Nilai terbesar dari setiap filter dengan ukuran yang telah ditentukan (misalnya, 2 x 2) akan diambil, dan sisanya diabaikan. Gambar 2.6 memberikan visualisasi cara bekerja max pooling pada matriks 4 x 4 dengan ukuran filter 2 x 2 dan stride 2.



Gambar 2.6. Langkah-langkah Max Pooling

Sedangkan, expansive path berfungsi untuk mengembalikan dimensi spasial ke ukuran dasarnya (upsampling) dengan menggunakan up-convolution. Up-convolution adalah sebuah operasi yang berkebalikan dengan convolution layer yang dilakukan di encoder. Proses ini akan memperbesar ukuran feature map ke ukuran aslinya secara bertahap sesuai dengan proses yang dilakukan di encoder, serta melakukan pembelajaran sesuai dengan konsep convolution layer. Pada saat melakukan upsampling, feature map dari proses encoder digabungkan dengan feature


map yang sedang dilakukan proses upsampling dengan tujuan untuk mempertahankan detail yang hilang saat melakukan downsampling menggunakan skip connection.

Terakhir, pada layer terakhir arsitektur U-Net digunakan fungsi aktivasi sigmoid untuk menghasilkan sebuah nilai probabilitas yang memiliki rentang nilai 0 hingga 1. Sigmoid umum digunakan untuk kasus klasifikasi biner, dimana nilai yang mendekati 1 dianggap positif dan nilai yang mendekati 0 dianggap negatif. Kemudian, nilai dari sigmoid akan diteruskan ke loss function Binary Cross Entropy untuk membandingkan nilai yang diprediksi dengan yang sebenarnya. Ditambah, nilai dari loss function akan digunakan untuk menghitung kembali nilai kernel untuk mengoptimalkan pembelajaran pada masing-masing layer. Rumus fungsi aktivasi sigmoid dapat dilihat pada rumus di bawah ini.

$$f(x) = \frac{1}{(1 + e^{-x})} \quad (8)$$

x = nilai input

e = logaritma natural $\approx 2,718$

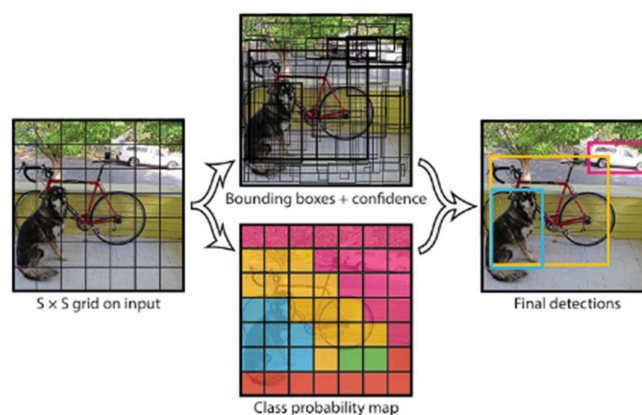


Gambar 2.7. Arsitektur U-Net

Gambar 2.7. adalah gambaran dari arsitektur U-Net yang dikembangkan oleh Ronnerberger pada tahun 2015 untuk melakukan image segmentation di bidang biomedical [17]. Berdasarkan eksperimen Ronnerberger, didapatkan kesimpulan bahwa arsitektur U-Net menunjukkan performa yang sangat baik pada pengaplikasian segmentasi biomedical yang berbeda-beda. Ronnerberger juga mengatakan bahwa arsitektur U-Net hanya membutuhkan sedikit data training dan waktu training yang singkat.

2.8. You-Only-Look-Once

YOLO adalah algoritma deteksi objek single-shot yang memproses keseluruhan citra dalam satu neural network tunggal untuk memprediksi bounding box, menghitung confidence score, dan probabilitas kelas untuk objek [20]. Arsitektur ini membagi citra masukan menjadi sebuah grid sel. Ketika pusat sebuah objek berada di dalam sel tertentu, sel tersebut bertanggung jawab untuk memprediksi bounding box dan probabilitas kelas objek, lihat Gambar 2.8. Algoritma ini memanfaatkan Convolutional Neural Network (CNN) sebagai backbone untuk ekstraksi fitur. Jaringan saraf ini memungkinkan prediksi bounding box dan probabilitas kelas untuk objek yang terdeteksi.



Gambar 2.8. Model YOLO

YOLOv8 memiliki prinsip yang sama dengan versi YOLO sebelumnya dengan pengenalan beberapa peningkatan. YOLOv8 menggunakan model anchor-free, berbeda dengan model anchor-


based pada versi YOLO sebelumnya. Sebuah perubahan arsitektural juga diperkenalkan, yaitu decoupled head untuk tugas-tugas terpisah: klasifikasi objek dan lokalisasi. Pemisahan ini memungkinkan model untuk fokus pada tugasnya masing-masing, yang pada gilirannya, meningkatkan akurasi dan kinerja secara keseluruhan. Modul C2f yang baru menggantikan modul C3 yang terdapat pada YOLOv5 sebelumnya [21]. Modul C2f ini bertanggung jawab untuk menggabungkan informasi fitur tingkat tinggi dan konteks untuk meningkatkan akurasi deteksi. YOLOv8 menggunakan fungsi sigmoid untuk memprediksi skor objectness (keberadaan objek) dari bounding box. Sementara itu, fungsi softmax digunakan untuk menghitung probabilitas kelas, yang mengindikasikan kemungkinan bahwa objek tersebut termasuk dalam kelas tertentu. Untuk menghitung error, YOLOv8 menggunakan kombinasi loss function CIOU dan DFL untuk bounding box loss, serta binary cross-entropy untuk classification loss. Fungsi-fungsi kerugian ini telah terbukti meningkatkan kinerja deteksi objek, termasuk untuk objek berukuran kecil.

YOLOv11 adalah peningkatan versi berikutnya dalam keluarga YOLO di bidang deteksi objek real-time (waktu-nyata) [22]. Model terbaru ini memiliki kinerja yang lebih baik dari versi sebelumnya. Arsitektur dan metode pelatihan yang ditingkatkan menghasilkan akurasi dan kecepatan yang lebih tinggi. YOLOv11 unggul dalam beragam tugas visi komputer, termasuk deteksi objek, segmentasi instans, estimasi pose, deteksi berorientasi, dan klasifikasi. Arsitektur YOLOv11 memiliki tiga bagian utama: (1) Backbone: Mengekstraksi fitur dari citra menggunakan convolutional neural network. Pada versi ini, blok C3k2 menggantikan blok C2f untuk mencapai biaya komputasi yang efisien. (2) Neck: Menggabungkan dan menyempurnakan fitur dari skala yang berbeda, untuk menangkap informasi multi-skala secara efektif. Attention Module C2PSA yang baru diperkenalkan pada iterasi ini untuk memberikan akurasi yang lebih tinggi pada deteksi objek. (3) Head: Menggunakan fitur yang telah disempurnakan untuk memprediksi lokasi dan kelas objek. Beberapa blok C3k2 menggantikan

blok C2f, dengan kemampuan tambahan untuk beralih secara opsional dari ekstraksi fitur cepat (biaya komputasi lebih rendah) ke deteksi yang jauh lebih akurat (biaya komputasi lebih tinggi).

2.9. Slicing Aided Hyper Inference

Mendeteksi objek kecil dalam citra beresolusi tinggi merupakan tantangan bagi detektor objek konvensional karena kekurangan detail yang memadai dan hanya mencakup sejumlah kecil piksel. SAHI adalah teknik pasca-pemrosesan yang membagi citra masukan berukuran besar menjadi potongan lebih kecil yang saling tumpang tindih selama proses inferensi, memungkinkan deteksi objek yang mungkin terlewatkan atau terlokalisasi dengan buruk saat memproses seluruh citra sekaligus [23].



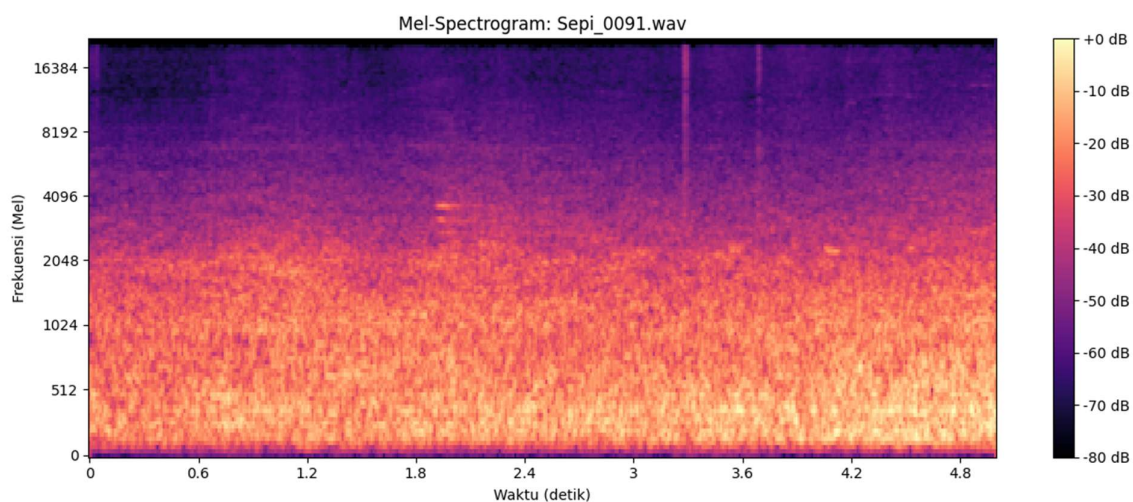
Gambar 2.9. SAHI Post-Processing

Selama inferensi, SAHI membagi citra masukan menjadi patch-patch (potongan) yang tumpang tindih, mengubah ukurannya, kemudian menjalankan deteksi objek pada setiap patch. Prediksi dari patch-patch tersebut kemudian digabungkan kembali ke koordinat citra asli. Proses ini dilakukan dengan menggunakan Non-Maximum Suppression (NMS). Pasca-pemrosesan SAHI dapat diintegrasikan ke dalam model inferensi deteksi objek apa pun tanpa pra-pelatihan, lihat Gambar 2.9.


2.10. Data Suara Kebisingan Jalan Raya

Suara pada suatu perkotaan adalah lanskap akustik kompleks yang mendefinisikan karakter sebuah kota. Pertumbuhan populasi dan urbanisasi yang pesat menyebabkan peningkatan dan diversifikasi kebisingan di perkotaan. Kebisingan ini dapat dimanfaatkan sebagai informasi penting dalam konsep smart city [24]. Dalam konteks perkotaan, studi menunjukkan bahwa sumber suara yang paling dominan di area urban adalah yang berasal dari aktivitas manusia dan lalu lintas. Pada penelitian yang sudah dilakukan, monitoring dan klasifikasi tingkat kebisingan jalan raya digunakan untuk memetakan daerah perkotaan [25]. Pemetaan ini memiliki tujuan untuk memberikan gambaran bagi perancang perkotaan untuk memperbaiki lalu lintas.


Untuk memastikan relevansi model dengan kondisi lokal, penelitian ini akan menggunakan dataset audio yang direkam dan dibangun secara mandiri. Dataset ini dirancang khusus untuk menangkap karakteristik akustik unik dari kondisi lalu lintas di kota Jakarta. Proses pengumpulan dataset akan melibatkan perekaman audio dan video secara simultan di lokasi penelitian yang telah ditentukan. Lokasi yang dipilih mewakili titik dengan volume lalu lintas yang beragam, mencakup kondisi padat saat jam sibuk dan lengang di luar jam sibuk. Audio akan menjadi data utama yang diolah, sedangkan video berfungsi sebagai alat bantu untuk proses anotasi (pelabelan) guna menghitung jumlah kendaraan secara akurat.



Gambar 2.10. Mel-Spektrogram Pada Kondisi Jalan Sepi



Gambar 2.11. Mel-Spektogram Pada Kondisi Jalan Lancar



Gambar 2.12. Mel-Spektogram Pada Kondisi Jalan Macet

Rekaman mentah berdurasi panjang kemudian akan melalui proses segmentasi dan anotasi, di mana rekaman tersebut dipotong menjadi klip-klip audio pendek (durasi 4-5 detik) dan diberi label secara manual ke dalam salah satu dari tiga kelas berikut:

1. Sepi: Klip audio dengan tingkat kebisingan latar yang rendah, di mana suara kendaraan yang lewat bersifat sporadis. Mel-Spektogram pada kondisi jalan sepi dapat dilihat pada Gambar 3.2.
2. Lancar: Klip audio yang ditandai oleh pola suara aliran kendaraan yang bergerak secara kontinu dan lebih ritmis. Mel-Spektogram pada kondisi jalan lancar dapat dilihat pada Gambar 3.3.

3. Macet: Klip audio yang secara akustik didominasi oleh suara klakson yang intens dan tidak teratur, serta dengungan mesin kendaraan yang cenderung stasioner. Mel-Spektrogram pada kondisi jalan macet dapat dilihat pada Gambar 3.4.

Kumpulan klip audio yang telah dilabeli ini akan menjadi dataset final yang digunakan untuk melatih dan mengevaluasi model deep learning dalam penelitian ini. Deep learning adalah cabang dari kecerdasan buatan (AI) yang menggunakan jaringan saraf tiruan dengan banyak lapisan (deep neural networks) untuk mengekstraksi fitur dan mempelajari representasi data dari data mentah. Teknik ini sangat efektif untuk mengatasi masalah yang melibatkan data yang besar dan kompleks, seperti gambar, suara, dan teks. Dalam konteks suara, deep learning memungkinkan sistem untuk secara otomatis mengenali pola-pola kompleks dalam sinyal audio tanpa memerlukan pengolahan manual yang rumit [26].

Klasifikasi suara adalah proses mengidentifikasi dan mengategorikan suara berdasarkan fitur-fitur yang terkandung di dalamnya. Dalam lingkungan perkotaan, suara-suara yang dihasilkan dapat mencakup klakson mobil, langkah kaki pejalan kaki, suara konstruksi, dan berbagai suara lainnya. Tantangan utama dalam klasifikasi suara lalu lintas adalah keragamannya yang sangat tinggi, yang dipengaruhi oleh berbagai faktor, seperti kondisi cuaca, kepadatan lalu lintas, dan aktivitas manusia. Deep learning mampu menangkap pola-pola yang sangat kompleks dalam suara yang seringkali sulit dipahami oleh metode analisis tradisional, sehingga meningkatkan akurasi dalam pengklasifikasian suara [27].

2.11. Ekstraksi Fitur Pada Data Suara Kebisingan Jalan Raya

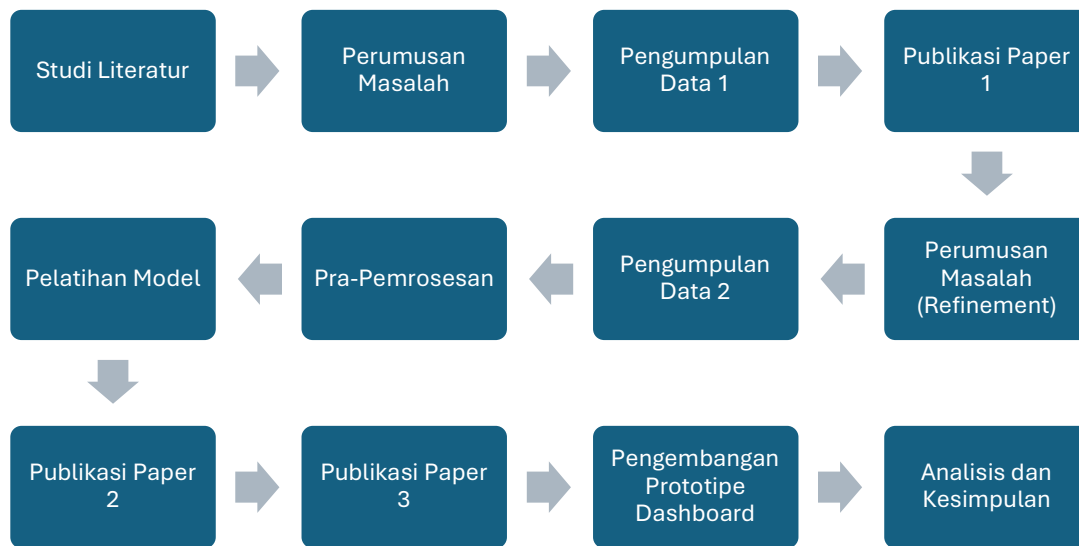
Ekstraksi fitur dalam analisis suara merupakan proses penting yang mengubah sinyal suara mentah menjadi representasi fitur yang dapat diolah oleh model machine learning. Salah satu metode ekstraksi fitur yang paling banyak digunakan adalah Mel-Frequency Cepstral Coefficients (MFCC). MFCC mengekstrak karakteristik spektral suara dengan meniru cara

kerja sistem pendengaran manusia. Proses ini mengubah data suara menjadi sekumpulan koefisien ringkas tanpa menghilangkan informasi penting melalui serangkaian tahapan yang diuraikan sebagai berikut [28]:

1. Input Audio & Pre-emphasis: Langkah awal adalah menerapkan filter pre-emphasis pada sinyal audio. Filter ini adalah filter FIR (first-order infinite impulse response) yang berfungsi untuk meningkatkan tingkat energi pada frekuensi yang lebih tinggi.
2. Frame Blocking: Sinyal audio, yang bersifat non-stasioner, dibagi menjadi segmen-segmen pendek atau frame. Sinyal audio biasanya dibagi menjadi frame berdurasi 20-30 milidetik. Hal ini dilakukan karena karakteristik sinyal dianggap tetap (stasioner) dalam interval waktu yang singkat.
3. Windowing: Fungsi window (jendela) diterapkan pada setiap frame. Jendela Hamming adalah pilihan yang sering digunakan untuk tujuan ini.
4. FFT (Fast Fourier Transform): Transformasi Fourier (khususnya Fast Fourier Transform atau FFT) diterapkan pada setiap frame berjendela untuk mengubah sinyal dari domain waktu ke domain frekuensi. Hasilnya adalah spektrum atau periodogram yang menunjukkan manifestasi domain frekuensi dari sinyal domain waktu.
5. Mel Filter Bank (Triangular Bandpass Filter): Filterbank Mel kemudian diterapkan ke spektrum daya (hasil FFT). Filter ini menggunakan triangular bandpass filter (filter lolos-pita segitiga) yang tersebar secara tidak merata di sepanjang skala frekuensi Mel—lebih padat di frekuensi rendah dan lebih renggang di frekuensi tinggi. Proses ini mengubah frekuensi dari skala Hertz linear ke skala Mel.
6. Logarithm of Filter Energy (Log10): Langkah selanjutnya adalah menghitung energi dalam setiap filter filterbank dan kemudian mengambil logaritmanya. Transformasi logaritmik ini membantu menormalkan nilai energi dan mengurangi sensitivitas terhadap fluktuasi kecil dalam amplitudo sinyal.

7. DCT (Discrete Cosine Transform): Akhirnya, Discrete Cosine Transform (DCT) diterapkan pada energi filterbank logaritmik. DCT mengubah domain frekuensi Mel kembali ke domain waktu. Hasil dari langkah ini adalah Mel Frequency Cepstral Coefficients (MFCCs). DCT juga membantu dalam de-korelasi energi dari pita energi sebelumnya.

2.12. Roadmap Penelitian



Gambar 2.13. Roadmap Penelitian

BAB 3. Metodologi Penelitian

3.1. Tahapan Penelitian

Penelitian ini akan dilaksanakan melalui serangkaian yang terdiri dari 5 tahapan, dimulai dari studi literatur, pengumpulan data, pembuatan model, sampai dengan kesimpulan penelitian. Tahapan penelitian dijelaskan sebagai berikut:


Tabel 3.1. Tahapan Penelitian

Tahap	Deskripsi
I	Studi Literatur dan Perumusan Masalah 1. Melakukan tinjauan pustaka mendalam mengenai teknik deteksi obyek berukuran kecil, teknik deteksi suara tingkat kemacetan lalu lintas, model prediksi kualitas udara, dan teknik fusi data multimodal. 2. Menentukan perumusan masalah serta menghasilkan roadmap penelitian.
II	Akuisisi dan pengumpulan data Mengumpulkan data dari seluruh sumber data yang diidentifikasi dalam ruang lingkup penelitian.
III	Pra-pemrosesan dan Ekstraksi Fitur 1. Pembersihan Data: Menangani missing values, outlier, dan normalisasi data sensor. 2. Ekstraksi Fitur: Menerapkan model Computer Vision pada data kamera untuk mengekstraksi fitur kepadatan lalu lintas. Menerapkan model Audio Processing pada data mikrofon untuk mengekstraksi fitur tingkat kebisingan sebagai dasar klasifikasi kemacetan. Mengolah data foto satelit untuk segmentasi tutupan lahan dan identifikasi sumber polutan stasioner. 3. Sinkronisasi Data: Menyelaraskan seluruh data dalam resolusi spasial dan temporal untuk persiapan fusi.
IV	Pengembangan dan Pelatihan Model 1. Merancang arsitektur model deep learning 2. Melatih dan melakukan optimasi hyperparameter tuning 3. Validasi dan evaluasi model
V	Analisis dan Penarikan Kesimpulan: 1. Menganalisis hasil prediksi model dan temuan dari dashboard 2. Menulis dan mempublikasi tulisan ilmiah 3. Menyusun laporan akhir penelitian

3.2. Desain Penelitian

Desain penelitian ini berbentuk studi yang menggunakan pendekatan data untuk pemodelan prediktif. Tahapan awal dimulai dengan pengambilan data multimodal yang akan digunakan untuk melatih model. Tahap selanjutnya adalah menyiapkan data melalui tahapan pra-

pemrosesan, ekstraksi fitur, dan data fusion. Setelah seluruh data telah disiapkan, model deep-learning dibangun bersamaan dengan melakukan fine tuning hyperparameter. Model yang telah dihasilkan kemudian digunakan dalam dashboard yang memiliki fungsi untuk melakukan perhitungan indeks kualitas lingkungan hidup, dan dapat menghasilkan prediksi di waktu mendatang. Alur desain penelitian digambarkan pada Gambar 3.1.



Gambar 3.1. Desain Penelitian

3.3. Luaran Penelitian

Target luaran penelitian yang dihasilkan berupa publikasi ilmiah, dataset publik, dan model deep learning. Berikut adalah luaran penelitian yang diharapkan:

Tabel 3.2. Luaran Penelitian

No	Bentuk	Deskripsi	Deskripsi
1	Makalah Ilmiah	International Conference Paper dengan topik “Optimizing Small Object Detection”	Pokok studi yang ditulis pada makalah ilmiah ini seputar penggunaan model dengan optimalisasi deteksi obyek kecil dari citra yang berasal dari satelit. Tujuannya adalah untuk mendeteksi obyek-obyek penghasil polutan udara.
2	Makalah Ilmiah	International Reputable Journal dengan topik “Deep Learning for City Traffic Level Classification”	Makalah ilmiah ini membahas kemajuan teknik dan use case terbaru seputar deteksi kemacetan jalan perkotaan, beserta tantangannya dalam kondisi sesungguhnya.
3	Makalah Ilmiah	Internasional Reputable Journal dengan topik “MHL-SmartEQI: Model Deep Learning untuk Indeks Kualitas Lingkungan Hidup Perkotaan dengan data multimodal”	Makalah ilmiah ini memiliki tujuan untuk menghasilkan model indeks kesehatan lingkungan hidup dalam skala hiperlokal.
4	Dataset	Urban Multimodal Hyper-Local Dataset	Dataset hasil fusi data multimodal yang dapat digunakan untuk penelitian selanjutnya.
5	Model	MHL-SmartEQI	Multimodal Hyper-Local Smart Environment Quality Index

3.4. Lokasi Penelitian

Lokasi penelitian utama adalah Provinsi DKI Jakarta. Mengingat keterbatasan sumber daya dan kebutuhan akan data yang padat, studi kasus akan difokuskan pada area yang lebih terbatas pada kota Jakarta Barat. Pemilihan lokasi spesifik akan didasarkan pada kriteria berikut:

1. Ketersediaan akses untuk merekam data dari ground sensor (video, suara, polutan udara).
2. Keragaman kondisi lalu lintas yang cukup bervariasi, untuk menjamin keseimbangan data.
3. Variasi tata guna lahan yang tinggi (campuran area residensial, komersial, dan jalan utama).

3.5. Indikator Pencapaian

Keberhasilan penelitian didasarkan pada indikator pencapaian dari rencana luaran yang akan dihasilkan sebagai berikut:

Tabel 3.3. Indikator Pencapaian

No	Bentuk	Deskripsi	Indikator Pencapaian
1	Publikasi Ilmiah	International Conference Paper dengan topik “Optimizing Small Object Detection”	Accepted pada International Conference
2	Publikasi Ilmiah	International Reputable Journal dengan topik “Deep Learning for City Traffic Level Classification”	Accepted pada Journal SCOPUS Q2
3	Publikasi Ilmiah	Internasional Reputable Journal dengan topik “MHL-SmartEQI: Model Deep Learning untuk Indeks Kualitas Lingkungan Hidup Perkotaan dengan data multimodal”	Accepted pada Journal SCOPUS Q2
4	Dataset	Urban Multimodal Hyper-Local Dataset	Dataset terpublish dan dapat diakses oleh publik, sebagai kontribusi kepada masyarakat dan komunitas ilmiah
5	Model	MHL-SmartEQI	Model terpublish dan dapat diakses oleh publik, sebagai kontribusi kepada masyarakat dan komunitas ilmiah

3.6. Alat dan Bahan Penelitian

Penelitian ini akan menggunakan alat dan bahan sebagai berikut:

Tabel 3.4. Alat dan Bahan Penelitian

No	Tipe	Nama	Deskripsi
1	Bahan	Data visual lalu lintas	Data berupa video dan gambar, yang menunjukkan kepadatan jalan raya.
2	Bahan	Data suara lalu lintas	Data berupa suara, yang menunjukkan kondisi kebisingan jalan raya.
3	Bahan	Data remote sensing tutupan lahan	Data diambil dari Sentinel-2, yang memberikan data berupa tutupan lahan. Data ini digunakan untuk segmentasi area perumahan, komersial, dan jalan raya.
4	Bahan	Data polutan udara	Data diambil dari sensor portable yang memberikan data berupa gas pencemar udara.
5	Alat	Kamera	Alat ini digunakan untuk mengambil data kondisi lalu lintas secara visual.
6	Alat	Microphone	Alat ini digunakan untuk mengambil data kondisi lalu lintas secara audio.
7	Alat	Sensor AQI	Alat ini digunakan untuk mengambil data gas pencemar udara.
8	Alat	Mesin Deep Learning	Alat ini digunakan untuk menghasilkan model.

BAB 4. JADWAL PENELITIAN

4.1. Jadwal Penelitian

Keseluruhan penelitian pada proposal ini dilaksanakan dalam jangka waktu 2 tahun. Kegiatan awal dimulai dari studi literatur dan perumusan masalah pada Januari 2025 sampai dengan masa sidang proposal pada November 2025. Tahap perumusan masalah ini adalah proses yang selalu berkembang sesuai dengan studi literatur yang dijalankan.

Tahap akuisisi data, pra-pemrosesan, dan pengembangan model dimulai dari April 2025 sampai dengan Maret 2026. Rentang waktu ini diambil cukup lama karena jangka waktu ini digunakan untuk mengambil data untuk ke-3 penelitian yang menjadi target luaran, yaitu berupa data foto udara, foto satelit, suara dan foto kemacetan pada jalan raya.

Pada November 2025 dilakukan conference untuk mempresentasikan temuan pada Paper 1, yang diikuti dengan pengerjaan dan pengumpulan Paper ke-2 dan ke-3 masing-masing pada Maret dan Juni 2026. Bersamaan dengan pengumpulan Paper ke-2 dan ke-3, dataset hasil penelitian yang dilakukan akan diberikan kepada komunitas open source sehingga dataset ini dapat digunakan oleh para peneliti selanjutnya yang ingin mengembangkan metode lebih lanjut.

Pada setiap tahapan penelitian terdapat luaran yang digunakan untuk melengkapi keseluruhan penelitian ini. Jadwal penelitian dapat dilihat pada Tabel 4.1. Jadwal Penelitian, sedangkan luaran pada setiap tahapan ada di Tabel 4.2. Deskripsi Luaran Tahapan Penelitian.

Tabel 4.1. Jadwal Penelitian

No	Deskripsi Pekerjaan	Tahun 2025				Tahun 2026			
		Q1	Q2	Q3	Q4	Q1	Q2	Q3	Q4
1	Studi Literatur dan Perumusan Masalah								
2	Akuisisi dan pengumpulan data								
3	Pengembangan dan Pelatihan Model								
4	Penulisan & Submit Paper 1								
5	Penulisan & Submit Paper 2								
6	Penulisan & Submit Paper 3								
7	Public Dataset								
8	Analisis dan Penarikan Kesimpulan								

Tabel 4.1. Deskripsi Luaran Tahapan Penelitian

No	Deskripsi	Luaran
1	Studi Literatur dan Perumusan Masalah	Proposal Penelitian
2	Akuisisi dan pengumpulan data	Dataset untuk Conference Paper 1
3	Pengembangan dan Pelatihan Model	Model untuk Conference Paper 1
4	Conference Paper 1	Tulisan ilmiah dengan topik “Optimizing Small Object Detection”
5	Submit Paper 2	Systematic Literature Review dengan topik “Deep Learning for City Traffic Level Classification”
6	Submit Paper 3	Tulisan ilmiah dengan topik “MHL-SmartEQI: Model Deep Learning untuk Indeks Kualitas Lingkungan Hidup Perkotaan dengan data multimodal”
7	Public Dataset	Urban Multimodal Hyperlocal Dataset
8	Analisis dan Penarikan Kesimpulan	Disertasi

DAFTAR PUSTAKA

- [1] Environmental Protection Agency, “Environmental Quality Index.” Accessed: Nov. 13, 2025. [Online]. Available: <https://www.epa.gov/healthresearch/environmental-quality-index-eqi>
- [2] “Méthodologique de l’Indice de qualité écologique (IQE) et de l’Indice de potentialité écologique (IPE).” Accessed: Nov. 13, 2025. [Online]. Available: <https://www.patrinat.fr/fr/actualites/guide-methodologique-iqe-et-ipe-6866>
- [3] Ministry of the Environment, “Environmental Quality Standards.” Accessed: Nov. 13, 2025. [Online]. Available: <https://www.env.go.jp/en/standards/>
- [4] Badan Pusat Statistik, *Statistik Lingkungan Hidup Indonesia 2024*.
- [5] Dinas Lingkungan Hidup Provinsi DKI Jakarta, *IKLH DKI Jakarta Tahun 2024*. 2024.
- [6] United Nations, “Sustainable Development Goals.” Accessed: Nov. 13, 2025. [Online]. Available: <https://sdgs.un.org/goals/goal11>
- [7] A. Ulya, T. D. Susanto, Y. S. Dharmawan, and A. P. Subriadi, “Major Dimensions of Smart City: A Systematic Literature Review,” *Procedia Comput Sci*, vol. 234, pp. 996–1003, 2024, doi: 10.1016/j.procs.2024.03.089.
- [8] Kementrian Lingkungan Hidup, “Lokasi Stasiun Pemantauan Indeks Standar Pencemar Udara.” Accessed: Nov. 08, 2025. [Online]. Available: <https://ispu.menlhk.go.id/webv5/#/stasiun>
- [9] Kementrian Lingkungan Hidup, “Peta Sebaran Stasiun Pemantauan ISPU”, Accessed: Nov. 08, 2025. [Online]. Available: <https://ispu.menlhk.go.id/webv5/#/peta>
- [10] “Sentinel-5P Mission.” Accessed: Nov. 08, 2025. [Online]. Available: <https://sentiwiki.copernicus.eu/web/s5p-mission>

- [11] Arief Budi Kusuma, Hariadi Kartodihardjo, and Yudi Setiawan, “Potential Improvement of Environmental Quality Index (EQI) Based on District Level Data. Case Study in Bekasi Regency,” *Jurnal Pengelolaan Sumberdaya Alam dan Lingkungan (Journal of Natural Resources and Environmental Management)*, vol. 12, no. 4, pp. 651–659, Nov. 2022, doi: 10.29244/jpsl.12.4.651-659.
- [12] I. Manisalidis, E. Stavropoulou, A. Stavropoulos, and E. Bezirtzoglou, “Environmental and Health Impacts of Air Pollution: A Review,” Feb. 20, 2020, *Frontiers Media S.A.* doi: 10.3389/fpubh.2020.00014.
- [13] J. Goossens, A. C. Jonckheere, L. J. Dupont, and D. M. A. Bullens, “Air pollution and the airways: Lessons from a century of human urbanization,” Jul. 01, 2021, *MDPI*. doi: 10.3390/atmos12070898.
- [14] I. Ulku and E. Akagündüz, “A Survey on Deep Learning-based Architectures for Semantic Segmentation on 2D Images,” 2022, *Taylor and Francis Ltd.* doi: 10.1080/08839514.2022.2032924.
- [15] J. Lv, Q. Shen, M. Lv, Y. Li, L. Shi, and P. Zhang, “Deep learning-based semantic segmentation of remote sensing images: a review,” 2023, *Frontiers Media SA*. doi: 10.3389/fevo.2023.1201125.
- [16] B. Emek Soylu, M. S. Guzel, G. E. Bostanci, F. Ekinici, T. Asuroglu, and K. Acici, “Deep-Learning-Based Approaches for Semantic Segmentation of Natural Scene Images: A Review,” *Electronics (Basel)*, vol. 12, no. 12, p. 2730, Jun. 2023, doi: 10.3390/electronics12122730.
- [17] O. Ronneberger, P. Fischer, and T. Brox, “U-Net: Convolutional Networks for Biomedical Image Segmentation,” 2015, pp. 234–241. doi: 10.1007/978-3-319-24574-4_28.

- [18] S. Aghayari, A. Hadavand, S. Mohamadnezhad Niazi, and M. Omidalizarandi, "BUILDING DETECTION FROM AERIAL IMAGERY USING INCEPTION RESNET UNET AND UNET ARCHITECTURES," *ISPRS Annals of the Photogrammetry, Remote Sensing and Spatial Information Sciences*, vol. X-4/W1-2022, pp. 9–17, Jan. 2023, doi: 10.5194/isprs-annals-X-4-W1-2022-9-2023.
- [19] X. Zhao, L. Wang, Y. Zhang, X. Han, M. Deveci, and M. Parmar, "A review of convolutional neural networks in computer vision," *Artif Intell Rev*, vol. 57, no. 4, Apr. 2024, doi: 10.1007/s10462-024-10721-6.
- [20] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, "You Only Look Once: Unified, Real-Time Object Detection," in *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, IEEE, Jun. 2016, pp. 779–788. doi: 10.1109/CVPR.2016.91.
- [21] R. Varghese and S. M., "YOLOv8: A Novel Object Detection Algorithm with Enhanced Performance and Robustness," in *2024 International Conference on Advances in Data Engineering and Intelligent Computing Systems (ADICS)*, IEEE, Apr. 2024, pp. 1–6. doi: 10.1109/ADICS58448.2024.10533619.
- [22] R. Khanam and M. Hussain, "YOLOv11: An Overview of the Key Architectural Enhancements," Oct. 2024.
- [23] F. C. Akyon, S. Onur Altinuc, and A. Temizel, "Slicing Aided Hyper Inference and Fine-Tuning for Small Object Detection," in *2022 IEEE International Conference on Image Processing (ICIP)*, IEEE, Oct. 2022, pp. 966–970. doi: 10.1109/ICIP46576.2022.9897990.
- [24] L. R *et al.*, "Urban Sound Classification with Convolutional Neural Network," in *2024 International Conference on Integrated Intelligence and Communication Systems (ICIICS)*, IEEE, Nov. 2024, pp. 1–6. doi: 10.1109/ICIICS63763.2024.10859876.

- [25] G. Brambilla, R. Benocci, C. Confalonieri, H. E. Roman, and G. Zambon, "Classification of urban road traffic noise based on sound energy and eventfulness indicators," *Applied Sciences (Switzerland)*, vol. 10, no. 7, Apr. 2020, doi: 10.3390/app10072451.
- [26] S. Barua, T. Akter, M. Abu, S. Musa, and M. A. Azim, "A Deep Learning Approach for Urban Sound Classification," 2023.
- [27] A. F. R. Nogueira, H. S. Oliveira, J. J. M. Machado, and J. M. R. S. Tavares, "Sound Classification and Processing of Urban Environments: A Systematic Literature Review," *Sensors*, vol. 22, no. 22, Nov. 2022, doi: 10.3390/s22228608.
- [28] K. Mohammed Rezaul *et al.*, "Enhancing Audio Classification Through MFCC Feature Extraction and Data Augmentation with CNN and RNN Models," 2024. [Online]. Available: www.ijacsa.thesai.org